Kırıkkale Üniversitesi
Elektrik-Elektronik Mühendisliği Bölümü

MÜH4002 Görüntü İşleme Dersi

2025-2026 Akademik Yılı

Final Raporu



YOLOv5 Tabanlı Araç Algılama Modeli

Metehan Tırpan[1], Seher Bozbıyık [2], Vildan Yılmazer [3]

[1]*223204039, Kırıkkale Üniversitesi, Elektrik-Elektronik Mühendisliği Bölümü, 71450 Kırıkkale, TÜRKİYE*
[2]*223204041, Kırıkkale Üniversitesi, Elektrik-Elektronik Mühendisliği Bölümü, 71450 Kırıkkale, TÜRKİYE*
[3]*223204003, Kırıkkale Üniversitesi, Elektrik-Elektronik Mühendisliği Bölümü, 71450 Kırıkkale, TÜRKİYE*

Özet

YOLOv5 mimarisi üzerine inşa edilen araç algılama modeli, akıllı ulaşım sistemlerinin anlık veri döngüsünü beslemek üzere doğrudan görsel girdilerle çalışmaktadır. Ağın sıfırdan eğitime alınması durumunda ortaya çıkacak donanımsal yükü ve zaman kısıtlamalarını ise, modelin hazır öznitelik haritalarından faydalanan transfer öğrenme (transfer learning) metodolojisiyle absorbe ettik. Bu doğrultuda, genel amaçlı COCO2017 veri kümesinin tamamını sisteme yüklemek yerine, yalnızca projenin odağını oluşturan araç sınıflarını filtreleyerek spesifik bir alt küme üzerinden ilerledik. Proje döngüsünde, ilk deneysel aşamada karşılaşılan küçük nesne kayıpları ve oklüzyon gibi darboğazları aşmak adına veri temizliği, etiket düzeltme ve parametre optimizasyonu süreçleri hayata geçirilmiştir. Geliştirilen sistemin nihai performansı Precision, Recall ve mAP metrikleri vasıtasıyla analiz edilmiştir. Elde edilen bulgular, optimize edilen YOLOv5 mimarisinin düşük gecikmeli hızlı çıkarım yeteneğiyle birlikte sahada yüksek doğruluk ürettiğini doğrulamaktadır. Çalışma, rafine veri altyapısının sinir ağları üzerindeki etkisini tescillerken; güvenlik ve trafik yönetimi senaryolarında derin öğrenmenin pratik uygulanabilirliğini göstermektedir.

Anahtar Kelimeler
Araç tespiti, YOLOv5, nesne tespiti, derin öğrenme, COCO2017 veri seti, transfer öğrenme.

**** Sorumlu Yazar:*** *vildan.yilmazer@hotmail.com*

Semboller

Sembol	Açıklama	Birim
x	Sınırlayıcı kutu merkezinin x koordinatı	piksel
y	Sınırlayıcı kutu merkezinin y koordinatı	piksel
w	Sınırlayıcı kutunun genişliği	piksel
h	Sınırlayıcı kutunun yüksekliği	piksel
B_pred	Tahmin edilen sınırlayıcı kutu	–
B_gt	Gerçek (etiketlenmiş) sınırlayıcı kutu	–
TP	Doğru pozitif tahmin sayısı	adet
FP	Yanlış pozitif tahmin sayısı	adet
TN	Doğru negatif tahmin sayısı	adet
FN	Yanlış negatif tahmin sayısı	adet
P	Precision (Kesinlik) değeri	%
R	Recall (Duyarlılık) değeri	%
F_1	F1-Skoru	%
IoU	Intersection over Union değeri	–
Map	Ortalama Ortalama Hassasiyet	%
W_pretrained	Önceden eğitilmiş model ağırlıkları	–
W_final	Eğitim sonrası elde edilen model ağırlıkları	–
L	Toplam kayıp (loss) değeri	–
N	Eğitimde kullanılan epoch sayısı	adet

Kısaltmalar

Kısaltma	Açılımı	Türkçe Karşılığı
AI	Artificial Intelligence	Yapay Zekâ
AP	Average Precision	Ortalama Hassasiyet
CNN	Convolutional Neural Network	Evrişimsel Sinir Ağı
COCO	Common Objects in Context	Ortak Nesneler Veri Seti
CPU	Central Processing Unit	Merkezi İşlem Birimi
CV	Computer Vision	Bilgisayarlı Görü
DL	Deep Learning	Derin Öğrenme
ECCV	European Conference on Computer Vision	Avrupa Bilgisayarlı Görü Konferansı
F1	F1-Score	F1 Başarım Ölçütü
FN	False Negative	Yanlış Negatif
FPN	Feature Pyramid Network	Özellik Piramidi Ağı
FPS	Frames Per Second	Saniyedeki Kare Sayısı
FP	False Positive	Yanlış Pozitif
GPU	Graphics Processing Unit	Grafik İşlem Birimi
IoU	Intersection over Union	Kesişim/Birleşim Oranı
mAP	Mean Average Precision	Ortalama Ortalama Hassasiyet
NMS	Non-Maximum Suppression	Maksimum Olmayan Bastırma
PANet	Path Aggregation Network	Yol Toplama Ağı
PASCAL VOC	Pattern Analysis, Statistical Modelling and Computational Learning Visual Object Classes	Görsel Nesne Sınıfları Veri Seti
PR Curve	Precision-Recall Curve	Kesinlik–Duyarlılık Eğrisi
PyTorch	Python Tabanlı Derin Öğrenme Kütüphanesi	–
SGD	Stochastic Gradient Descent	Stokastik Gradyan İnişi
TN	True Negative	Doğru Negatif
TP	True Positive	Doğru Pozitif
VOC	Visual Object Classes	Görsel Nesne Sınıfları
YOLO	You Only Look Once	Tek Bakışta Tespit
YOLOv5	You Only Look Once Version 5	YOLO'nun 5. Sürümü
YOLOv8	You Only Look Once Version 8	YOLO'nun 8. Sürümü

1. Giriş

Kentleşmeyle beraber tırmanışa geçen araç yoğunluğu; yol güvenliği, dinamik trafik yönetimi ve akıllı ulaşım altyapılarında esnek otomasyon çözümlerini zorunlu kılmaktadır. Bu ekosistemde, görsel veriler üzerinden araçların anlık tespiti ve sınıflandırılması; otopark kontrolünden yoğunluk haritalama senaryolarına kadar geniş bir sahada kritik veri girdisi sağlar. Ancak konvansiyonel bilgisayarlı görü algoritmaları; değişken ışık kırılmaları, oklüzyon (örtüşme) ve ölçek kararsızlıkları karşısında operasyonel esnekliğini kaybetmektedir. Söz konusu bu kısıtlamaları aşmada, derin öğrenme tabanlı nesne algılama mimarileri yüksek kararlılık ve anlık çıkarım yetenekleriyle güçlü birer alternatif sunar [10]. Özellikle tek aşamalı (one-stage) dedektör sınıfının öncüsü olan YOLO altyapısı, işlem hızı ile başarım oranları arasında optimum bir denge kurmaktadır [11]. Bu motivasyonla yürütülen çalışmada, COCO2017 veri kümesinin araç sınıflarından rafine edilen bir seçki üzerinden YOLOv5 tabanlı bir tespit sistemi kurgulanmış ve ağın öğrenme performansını optimize edecek revizyonlar hayata geçirilmiştir [5], [7].

Bilgisayarlı görü (computer vision) literatüründe, görüntü işleme ve derin öğrenme tabanlı nesne algılama mekanizmaları son dönemin en dinamik araştırma odaklarından birini teşkil etmektedir. Bu ekosistemde araç tespiti; otonom sürüş algoritmalarından akıllı ulaşım altyapılarına ve anlık kavşak yönetim sistemlerine kadar geniş bir sahada çekirdek veri girdisi sağlar. Süreçteki temel başarı kriteri, akan video sinyallerindeki veya durağan görsellerdeki araçların koordinat düzeyinde doğru konumlandırılması ve gerçek zamanlı sınıflandırılmasıdır. Konvansiyonel bilgisayarlı görü yaklaşımları; özellik çıkarımı, kenar bulma ve klasik makine öğrenmesi adımlarına dayanması sebebiyle karmaşık trafik sahneleri ve değişken ışık kırılmaları karşısında operasyonel esnekliğini kaybetmektedir. Söz konusu kararsızlıklar, derin öğrenme tabanlı katmanlı mimarilerin sahada baskın bir şekilde tercih edilmesini doğrudan tetiklemiştir.

Nesne algılama kronolojisindeki en radikal kırılma, şüphesiz YOLO (You Only Look Once) geometrisinin tasarlanmasıdır. Algoritma, nesne tespiti problemini tek bir regresyon matrisine indirgeyerek görüntü genelinde eş zamanlı bir sınıflandırma ve sınırlayıcı kutu (bounding box) kestirimi yürütür [10]. Bu mimari strateji, Faster R-CNN gibi çift aşamalı (two-stage) hantal dedektörlerin getirdiği yüksek hesaplama maliyetlerini ortadan kaldırarak sisteme ciddi bir operasyon hızı kazandırmıştır [12]. YOLO ailesi; doğruluk ve çıkarım (inference) performansı arasındaki dengeyi optimum noktaya taşımak adına v2, v3 ve v4 fazlarıyla evrilmiştir [2]. Ultralytics tarafından PyTorch ekosisteminde yapılandırılan YOLOv5 ise, kolay eğitilebilirlik ve entegrasyon esnekliğiyle öne çıkmıştır. Sunulan farklı model ölçekleri (s, m, l, x), algoritmanın çeşitli donanım sınırlarına göre esnekçe ölçeklenmesine olanak tanımaktadır [5].

Literatürün daha güncel bir halkası olan YOLOv8; çapasız (anchor-free) tasarım geometrisi ve ayrık tahmin başlığı (decoupled detection head) gibi yapısal modülleriyle YOLOv5'e kıyasla daha keskin doğruluk skorları üretmektedir. Ayrıca optimizasyon döngülerinde daha kararlı bir yakınsama çizgisi yakalayarak hata paylarını minimize eder [15]. Bu yönüyle YOLOv8, özellikle milisaniye düzeyinde çıkarım gerektiren canlı saha senaryolarında güçlü bir alternatif olarak konumlanmaktadır.

Modellerin eğitim ve benchmark aşamalarında en yaygın referans alınan kaynakların başında Microsoft COCO (Common Objects in Context) veri havuzu gelir. Barındırdığı 80 farklı nesne sınıfı ve geniş görsel varyasyonları, evrişimli sinir ağlarının genelleme kabiliyetini doğrudan optimize eder [7]. Nesne tespiti araştırmalarında altın standart kabul edilen COCO 2017 sürümü; eğitim, doğrulama ve test olarak ayrılmış rafine bir koleksiyona sahiptir. Havuz içerisindeki araç kategorileri (car, bus, truck, motorcycle, bicycle) özellikle trafik mühendisliği projelerinde temel veri seti olarak yapılandırılmaktadır.

Mevcut literatür incelendiğinde, YOLO tabanlı modellerin yüksek doğruluk ve gerçek zamanlı operasyon kabiliyetini eş zamanlı sunduğu tescillenmiştir. YOLOv4 ve YOLOv5 altyapıları, COCO genel testlerinde rüştünü ispatlayarak birçok ticari ve akademik uygulamada kendilerine yer bulmuştur [2], [5]. Öte yandan YOLOv8'in gelişmiş katman yapısı sayesinde özellikle perspektif olarak uzakta kalan küçük nesne kayıplarını engellemede daha başarılı sonuçlar verdiği rapor edilmektedir [15]. Ancak bu ağların tamamında nihai performans; veri setinin bilgi yoğunluğuna, etiket kalitesine ve hiper-parametre kararlılığına doğrudan bağımlıdır.
Yürüttüğümüz bu çalışma kapsamında, COCO 2017 veri tabanından süzülen araç sınıfları referans alınarak YOLOv5 tabanlı bir araç tespit sistemi modellenmiştir. Algoritma transfer öğrenme (transfer learning) yaklaşımıyla eğitime alınmış ve anlık araç yakalama performansı sayısal metriklerle analiz edilmiştir [5], [9]. Elde edilen deneysel çıktılar, YOLO tabanlı yaklaşımların karmaşık trafik senaryolarında son derece etkin, uygulanabilir ve pratik mühendislik çözümleri sunduğunu doğrulamaktadır.

YOLOv5 mimarisi, akıllı ulaşım altyapılarının dinamik veri gereksinimlerini doğrudan görüntüler üzerinden karşılayabilmek adına çalışmanın çekirdeğine konumlandırılmıştır [5]. Model seçimindeki temel motivasyonumuz; derin öğrenme literatüründe kronik bir problem olan yüksek hesaplama maliyetlerini baskılamak ve sahada koşturulacak gerçek zamanlı uygulamalarda hız-başarım dengesini optimum bir çizgide yakalayabilmekti. Mevcut modellerin genel amaçlı doğası ve veri kümesi kısıtları yüzünden spesifik sahalara uyarlanırken sergilediği kararsızlıklar, projenin tasarım safhasındaki en net çıkış noktamız olmuştur [2], [10].

Geliştirilen sistemin literatüre sağladığı temel katkı, COCO2017 veri havuzunun araç sınıflarına göre el ile temizlenip filtrelenmesi ve transfer öğrenme yaklaşımıyla eğitim döngülerinin radikal biçimde hızlandırılmasıdır [7], [9]. Jenerik nesne tespit ağlarının belirli bir problem alanına kanalize edildiğinde ne denli verimli sonuçlar üretebileceğini tescilleyen bu çalışma hem yüksek doğruluk hem de minimum gecikme süresi (low latency) hedefleyen, doğrudan uygulama odaklı ve sahaya entegre edilebilir bir mühendislik çözümü ortaya koymaktadır.

2.Materyal ve Yöntemler

2.1. Materyal

2.1.1. Kullanılan Veri Setinin Tanımlanması

Bu çalışmada gerçekleştirilen araç tespit (vehicle detection) modelinin eğitimi, doğrulanması ve test edilmesi süreçlerinde, bilgisayarlı görü literatüründe nesne tespiti, segmentasyon ve etiketleme alanlarında standart bir kıyaslama (benchmark) kabul edilen MS COCO (Microsoft Common Objects in Context) 2017 veri seti kullanılmıştır [7]. İlgili veri setine Kaggle platformu üzerinden dijital açık kaynak olarak erişim sağlanmıştır [1].

2.1.2. Görüntü Özellikleri ve Veri Formatı



Şekil 1: Örnek Test Verisi

- **Görüntü Formatı:** Veri setinde yer alan tüm görsel içerikler .jpg (JPEG) formatında depolanmaktadır.
- **Görüntü Boyutları (Çözünürlük):** COCO 2017 veri setindeki görüntüler sabit bir boyuta sahip olmayıp değişken çözünürlüklere sahiptir [7]. Modelin eğitim aşamasında bu görüntüler, algoritmanın giriş katmanına uygun biçimde yeniden boyutlandırılmıştır (resizing).
- **Anotasyon (Etiket) Formatı:** Orijinal veri setinin etiket formatı JavaScript Object Notation (.json) yapısındadır [7]. Bu dosya içerisinde her bir görüntüye ait kimlik bilgileri, bounding box (sınırlayıcı kutu) koordinatları $x_{min}, y_{min}, genişlik, yükseklik$) ve kategori sınıfları tutulmaktadır. Araç tespiti mimarisinde (örneğin YOLO serisi kullanıldıysa) bu koordinatlar normalize edilerek her görüntüye özel .txt formatına dönüştürülmüştür.

2.1.3. Veri Setinin Dağılımı ve Bölütlenmesi

Veri setinin toplam örneklem havuzu, modelin ezberlemesini (overfitting) önlemek ve genelleme yeteneğini objektif değerlendirebilmek adına endüstri standartlarında üç temel alt gruba bölünmüştür [7]:

1. **Eğitim Seti (Training Set)**
2. **Doğrulama Seti (Validation Set)**
3. **Test Seti (Test Set)**

Ancak veri seti çok büyük olduğundan raporun ilerleyen kısımlarında açıklandığı gibi manuel olarak veri seti ayıklanmıştır ve yaklaşık 1.2GB boyutuna düşürülmüştür.

2.1.4. Sınıfsal Dağılım ve Araç Odaklı Filtreleme

MS COCO veri seti standart haliyle 80 farklı nesne sınıfı içerse de [7] bu projede hedefimizi araç tespitiyle sınırlandırdık. Bu yüzden yalnızca trafik akışında yer alan ulaşım araçlarını ve bunlara ait anotasyon verilerini filtreleyerek işleme aldık. Yoğunluk analizi ve trafik takibi için belirlediğimiz hedef sınıfları şu mantıkla seçtik:

- Veri setinin genelinde en fazla örneğe sahip, yoğunluğu en yüksek baskın sınıf olarak **otomobilleri (car)** aldık.
- Toplu taşıma tarafını yönetebilmek adına, kamyonlardan yapısal olarak daha farklı öznitelikler taşıyan **otobüs (bus)** sınıfını dahil ettik.
- Küçük ölçekli yapıları yüzünden trafikte önü kapanmaya (oklüzyona) oldukça müsait olan iki tekerleklileri ise **motosiklet (motorcycle) ve bisiklet (bicycle)** olarak iki ayrı grup halinde sisteme dahil ettik.

2.2. Kullanılan Platformun tanımlanması

Büyük veri boyutları ve yoğun matris çarpımlarının yarattığı yüksek hesaplama yükü nedeniyle, araç tespit modelinin eğitim sürecinde bulut tabanlı bir yüksek performanslı hesaplama (HPC) altyapısı kullanılması gerekmiştir. Geliştirme aşamalarında doğrudan Google Colab platformu tercih edilirken; dosya yönetimi, veri depolama ve sürümleme gibi kritik süreçler ise bu sistemle uyumlu biçimde Google Drive bulut ekosistemi üzerinden yürütülmüştür.

2.2.1. Bulut Donanım (Hardware) Altyapısı

Model optimizasyonu ile ileri ve geri yayılım (forward/backward propagation) aşamalarındaki hesaplama yükünü hafifletmek için Google Colab'in sağladığı sanal makine altyapısı kullanılmıştır. Sistemin teknik detayları şu şekildedir:

- **NVIDIA Tesla T4 GPU:** Yüksek paralel işlem gücü ve geniş VRAM kapasitesi sayesinde, derin öğrenme katmanlarındaki ağır tensör operasyonları ile büyük paket boyutları (batch size) herhangi bir darboğaz yaşanmadan işlenmiştir.
- **Intel Xeon @ 2.20GHz CPU:** Veri setinin hatlar (pipeline) üzerinde taşınmasından, ön işleme adımlarından ve veri yükleme (data loading) süreçlerinin yönetiminden sorumlu merkez unsur olarak konumlandırılmıştır.
- **12.7 GB Sistem Belleği (RAM):** Eğitim döngüleri (epoch) esnasında gerçekleşen matris karıştırma işlemleri ve genel veri akışının kesintisiz, kararlı bir şekilde yürütülmesini sağlamıştır.

2.2.2. Veri Yönetimi ve Depolama Altyapısı

Depolama Alanı (Cloud Storage): Kaggle üzerinden temin edilen MS COCO 2017 araç veri seti ve etiket dosyaları [1], eğitim esnasında yerel disk kayıplarını önlemek ve kalıcı bir depolama sağlamak amacıyla bulut tabanlı Google Drive mimarisine yüklenmiştir.

- Anotasyon ve Veri Akışı (Data Pipeline): Google Colab üzerinde hazırlanan Python betiği, Google alt yapısına özel google.colab kütüphanesi ve POSIX dosya sistem köprüsü (Drive Mount) kullanılarak kullanıcıya ait Google Drive dizinine güvenli bir şekilde bağlanmıştır (/content/drive). Bu sayede veri setindeki binlerce .jpg formatındaki araç görseli ve .txt/.json formatındaki etiket dosyaları, eğitim algoritmasına doğrudan akış halinde (streaming) beslenmiştir.

2.2.3. Yazılım ve Geliştirme Ortamı (Software)

Projenin kodlama, test, hiperparametre optimizasyonu ve entegrasyon süreçlerinde açık kaynak kodlu yazılım ekosistemleri kullanılmıştır:

- **Çalışma Platformu (IDE):** Kodların etkileşimli, bloklar halinde test edilebilmesi ve grafiksel çıktıların anlık takibi amacıyla bulut tabanlı **Google Colab Notebook (Jupyter Ortamı)** kullanılmıştır.
- **Programlama Dili:** Veri bilimi ve bilgisayarlı görü uygulamalarında standart kabul edilen **Python 3.10+** dili tercih edilmiştir.

3. Yöntemler

3.1. YOLOv5 ile Nesne Tespiti

Araçların video veya görsellerden yakalanması sürecinde, nesne tespiti görevini tek bir regresyon problemi olarak ele alan derin öğrenme tabanlı YOLOv5 mimarisi kullanılmıştır [5]. Geleneksel yaklaşımlar önce potansiyel nesne bölgelerini seçip ardından sınıflandırma yaparken; YOLO yaklaşımında görüntü tek bir ağ üzerinden geçirilir ve sınırlayıcı kutu koordinatları ile sınıf öznitelikleri eş zamanlı hesaplanır [10]. Mimarinin işleyişi ve öznitelik yönetimi şu üç ana bileşen üzerinden yürütülmektedir:

- **Backbone (CSPDarknet53):** Girdi görsellerinden anlamlı parametrelerin soyutlanmasını sağlayan omurga altyapısıdır [5]. Giriş katmanından gelen verileri işleyerek kenar, köşe gibi düşük seviyeli görsel ipuçlarından, doğrudan araç formlarına odaklanan yüksek seviyeli yapısal özellikleri yakalamakla görevlidir [4], [13].

- **Neck (FPN & PANet Entegrasyonu):** Ağın farklı derinliklerinden elde edilen özellik haritalarını bir araya getiren ara katmandır. Yapı içerisinde kullanılan FPN [6] ve PANet [8] ağ yapısı, özniteliklerin yukarıdan aşağıya ve aşağıdan yukarıya doğru çift yönlü akmasını sağlayarak trafikteki irili ufaklı (uzaktaki motosikletler veya yakındaki otobüsler gibi) tüm araçların yakalanma performansını artırır.

- **Detection Head (Çıktı Katmanı):** Elde edilen nihai öznitelik haritalarını anlamlandırarak karar veren son mekanizmadır [5]. Bu katmanda her bir araç adayı için nesne sınıfı, koordinat verileri ve tahmin güvenilirliğini gösteren güven skoru eş zamanlı olarak hesaplanır. Sürecin son çıktısı olarak ise araçların konumunu tam olarak belirleyen sınırlayıcı kutular (Bounding Box) üretilmiş olur [10].

3.2. Bounding Box (Sınırlayıcı Kutu) Tahmini

Araçların görsel pikseller üzerindeki konum bilgisi, sınırları belirli kutular yardımıyla sembolize edilir. Bu doğrultuda her bir sınırlayıcı kutu, uzaysal boyutları ve konumunu netleştiren şu parametre bileşenlerinden meydana gelir:

$$B = (x, y, w, h)$$

- x ve y Öznitelikleri: Tahmin edilen kutunun tam merkez noktasına ait yatay (x) ve dikey (y) koordinat değerlerini gösterir.
- w (Genişlik) Parametresi: Sınırlayıcı kutunun yatay eksende kapladığı toplam piksel mesafesini (width) ifade eder.
- h (Yükseklik) Parametresi: Nesneyi çevreleyen yapının dikey eksendeki toplam boyunu (height) tanımlar.

YOLOv5 mimarisi, eğitim sürecinde gerçeğe en yakın nesne konumunu yakalayabilmek adına her araç kestirimi için bu parametre matrisini hesaplamaktadır [5].

3.3. Intersection over Union (IoU)

Modelin ürettiği konum tahminlerinin ne derece doğru olduğunu doğrulamak adına, tahmin edilen sınırlayıcı kutu ile gerçek etiket kutusu arasındaki örtüşme oranı IoU metriğiyle analiz edilir [10]. Ölçütün hesaplanmasında kullanılan matematiksel bağıntı şu şekildedir:

$$IoU = \frac{Area(B_{pred} \cap B_{gt})}{Area(B_{pred} \cup B_{gt})}$$

Bu bağıntıda yer alan B_{pred} bileşeni modelin tahmin matrisini, B_{gt} ise gerçeği yansıtan referans kutuyu sembolize eder. Piksel tabanlı bu oranlama sonucunda ortaya çıkan skor 0 ile 1 arasında sınırlandırılmıştır:

- IoU = 1 Durumu: Tahmin mekanizmasının hatasız çalıştığını ve kutuların bütünüyle çakıştığını (tam eşleşme) doğrular.
- IoU = 0 Durumu: Model çıktısı ile hedef nesne arasında hiçbir uzaysal örtüşmenin gerçekleşmediğini belirtir.

Bilgisayarlı görü süreçlerinde, elde edilen IoU çıktısının yüksekliği, araç tespiti modelinin konumlandırma hassasiyetinin başarısını temsil etmektedir [10], [12].

3.4. Non-Maximum Suppression (NMS) ile Filtreleme

Derin öğrenme tabanlı nesne tespit modelleri, doğası gereği aynı araç odağında birden çok sınırlayıcı kutu üretme eğilimindedir [10]. Bu durumun önüne geçmek ve en doğru tahmini seçebilmek için Non-Maximum Suppression (NMS) algoritması devreye sokulur. Algoritmanın işleyiş mantığı ve operasyonel adımları şu şekildedir:

- **Güven Skoru Tabanlı Sıralama:** Elde edilen tüm araç adayı kutuları, modelin ürettiği doğruluk ve güven skorlarına göre en yüksekten en düşüğe doğru bir hiyerarşiye alınır.

- **Baskın Kutunun Seçimi ve İzolasyonu:** Listedeki en yüksek güven skoruna sahip olan birincil kutu temel referans noktası olarak seçilir ve nihai çıktı listesine taşınır.

- **Mükerrerliklerin IoU ile Elenmesi:** Seçilen bu baskın kutu ile örtüşen diğer tüm kutular arasında IoU analizi yapılır. Belirlenen kritik eşiği aşan (yani aynı aracı çevrelediği anlaşılan) alternatif kutular sistemden temizlenir.

- **Yinelemeli Döngü Yönetimi:** Yukarıdaki eleme adımları, veri havuzunda işlenmemiş hiçbir aday kutu kalmayana dek dinamik olarak tekrarlanır.

Bu yinelemeli filtreleme stratejisi, yoğun trafik sahnelerinde araçların çoklu etiketlenmesini önleyerek sistemin nesne sayım doğruluğunu doğrudan optimize eder [10].

3.5. Transfer Öğrenme (Transfer Learning) Yaklaşımı

Derin evrişimli sinir ağlarının sıfırdan eğitilmesinin getireceği yüksek hesaplama yükünü ve kararsızlıkları önlemek adına projede transfer öğrenme metodolojisinden yararlanılmıştır [9]. Sürecin işleyişi ve parametre dönüşümü şu şekildedir:

Modelin ilk kurulumunda, milyarlarca görsel özniteliği halihazırda bünyesinde barındıran önceden eğitilmiş YOLOv5 ağırlık matrisi ($W_{Pretrained}$) referans alınmıştır [5]. Bu temel katmanlar, bizim spesifik trafik ve araç veri setimiz üzerinden geriye yayılım algoritmalarıyla yeniden optimize edilerek amaca yönelik nihai ağırlık setine (W_{Final}) dönüştürülmüştür.

Uygulanan bu transfer öğrenme mimarisi, sisteme operasyonel ve teorik açıdan şu kritik avantajları kazandırmıştır [9]:

- **Hesaplama Zamanı ve Yakınsama Optimizasyonu:** Ağın sıfırdan öğrenmesi gereken temel geometrik formlar (kenarlar, dokular) hazır geldiği için eğitim döngülerinin (epoch) kararlı bir noktaya ulaşma süresi kısalmıştır.
- **Veri Verimliliği ve Genelleme Yeteneği:** Sınırlı etiketli veri miktarlarında bile modelin nesne ayırt etme yeteneğini en üst düzeyde tutmasına imkan sağlamıştır.
- **Regülasyon ve Ezberleme Kontrolü:** Modelin ağırlık uzayını dengeli bir noktadan başlattığı için ağın eğitim verisine aşırı uyum sağlayarak ezberlemesi (overfitting) olasılığını doğrudan düşürmüştür.

3.6. Model Başarı ve Performans Ölçütleri

Eğitim ve test süreçleri tamamlanan nesne tespit mimarisinin analizinde, sistemin kararlılığını ve hata paylarını izlemek amacıyla şu performans göstergeleri kullanılmıştır:

- **Precision (Kesinlik):** Modelin araç olarak tahmin ettiği nesne havuzunun gerçekte yüzde kaçının doğru sınıfa ait olduğunu gösterir. Doğru pozitiflerin (TP), toplam pozitif tahminlere (TP+FP) oranlanmasıyla hesaplanır:

$$Precision = \frac{TP}{TP + FP}$$

- **Recall (Duyarlılık / Yakalama Oranı):** Sahada var olan gerçek araçların ne kadarının sistem tarafından başarılı bir şekilde fark edildiğini sembolize eder. Modelin gözden kaçırdığı araçları (FN) ölçeklendirmek için kritik bir parametredir:

$$Recall = \frac{TP}{(TP + FN)}$$

- **F1-Score:** Kesinlik ve duyarlılık parametrelerinin asimetrik dağılım sergilediği durumlarda objektif bir denge kuran ve bu iki değerin harmonik ortalamasını alan kararlılık indeksidir:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- **Mean Average Precision (mAP):** Bilgisayarlı görü literatüründe model doğruluğunu tescilleyen en kapsamlı başarı ölçütüdür [3], [7]. Proje analizinde, 0.5 IoU eşiğindeki model doğruluğunu veren mAP@0.5 ile modelin konumlandırma kalitesini en sıkı şekilde ölçen mAP@0.5:0.95 metrik varyasyonları baz alınmıştır. Bu skorların yükselmesi, ağın genel başarım seviyesinin arttığı anlamına gelir.

3.7. Yöntemin Güçlü ve Zayıf Yönlerinin Analizi

Projede uygulanan derin öğrenme modelinin saha performansını ve operasyonel sınırlarını belirleyen kriterler şu şekilde özetlenebilir: Sistemin Güçlü Yönleri (Avantajlar):

- Mimarinin Getirdiği Gerçek Zamanlı Çalışma Performansı: Tek aşamalı sinir ağı tasarımının sunduğu operasyonel hız [10], akan trafik videoları üzerinde çalışırken gecikmelerin önüne geçmektedir. Bu durum, sistemin sahada canlı bir izleme aracı olarak konumlandırılabilmesini doğrudan kolaylaştırır.
- Farklı Araç Türlerinin Tek Seferde Tanınması: Mimarinin doğası gereği otomobil, otobüs, motosiklet gibi çeşitli sınıflar aynı anda taranıp etiketlenebilir [5]. Tüm bu kategorileri tek bir çıkarım döngüsü içerisine sıkıştırmak, işlem maliyeti tarafında bize çok ciddi bir esneklik ve hız kazandırmaktadır.

- Transfer Öğrenmenin Sağladığı Veri Avantajı: Projede hazır ağırlıklardan yararlanılması [5], derin öğrenme modellerinin en büyük problemi olan yüksek veri ihtiyacını minimize etmiştir [9]. Sistem, geniş bir veri havuzu olmasa dahi aşırı öğrenme riskini baskılayarak kararlı sonuçlar üretmektedir.
- Donanım Optimizasyonu: Grafik işlem birimlerinin (GPU) paralel hesaplama mimarisinden maksimum düzeyde yararlanarak tensör operasyonlarını hızlandırır.

Sistemin Kısıtları ve Hassasiyetleri (Dezavantajlar):

- Ölçek Değişimlerine Duyarlılık: Perspektif olarak kameraya uzak kalan veya kadrajda küçük bir piksel alanı kaplayan nesnelerin tespitinde doğruluk oranı düşebilmektedir.
- Veri Kalitesine Bağımlılık: Giriş görsellerinin çözünürlük seviyelerindeki düşüşler ve anotasyon (etiketleme) aşamasında yapılan insan kaynaklı hatalar modelin kararlılığını doğrudan olumsuz etkiler.
- Hesaplama Maliyeti: Modelin eğitim süreçleri, donanım tarafında yüksek performanslı hesaplama (HPC) kaynaklarına ve ciddi bir işlem gücüne ihtiyaç duyar.
- Karmaşık Sahnelerde Yanılma Payı: Işık değişimlerinin, gölgelerin veya araçların üst üste binme durumlarının yoğun olduğu sahnelerde yanlış pozitif (false positive) tespit eğilimi artabilir.

4. Önerilen Model ve Sonuçlar

4.1. Önerilen Model Altyapısı

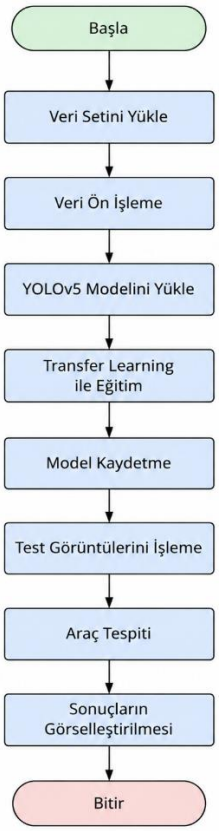
Görseller üzerinde araç tespiti ve sınıflandırma görevlerini yerine getirmek amacıyla çalışmada YOLOv5 nesne tespit mimarisi konumlandı [5]. Bu doğrultuda, COCO gibi büyük veri kümelerinde [7] önceden yakınsamış hazır ağırlık parametrelerini baz alarak, ağı kendi topladığımız araç veri setine göre ince ayarlamaya tabi tuttuk. Sistemin temel görevi, girdi olarak verilen karelerdeki araç konumlarını geometrik olarak sınırlayıp ait oldukları kategorileri eş zamanlı hesaplamaktır.
Projenin hedeflerine ulaşması adına yürütülen operasyonel iş akışı ve metodolojik adımlar şu şekildedir:

- **Veri Kümesinin Yapılandırılması ve Ön Hazırlık:** Hedef sahaya uygun araç görsellerinin bir araya getirilerek mimariye uygun formatta derlenmesi.
- **Anotasyon ve Nesne Etiketleme Süreci:** Görüntüler içerisindeki araçların sınırlayıcı kutu koordinatlarının ve sınıf bilgilerinin el ile işaretlenmesi.
- **Eğitim ve Doğrulama Ayrımı:** Modelin ezberlemesini önlemek amacıyla veri setinin stratejik oranlarda eğitim ve validasyon alt kümelerine bölüşülmesi.
- **Ağın Transfer Öğrenme ile Optimizasyonu:** YOLOv5 altyapısının hazır öznitelik haritaları kullanılarak araç veri seti üzerinde eğitime alınması [9].
- **Metrik Tabanlı Başarım Değerlendirmesi:** Eğitim döngüleri sonunda ortaya çıkan kayıp (loss) ve mAP değerlerinin incelenerek model kararlılığının ölçülmesi.
- **Çıkarım (Inference) ve Saha Testleri:** Eğitilen nihai modelin test görselleri üzerinde koşturularak araçları yakalama performansının gözlemlenmesi.
- **Bulguların Analitik İncelenmesi:** Elde edilen sayısal ve görsel çıktıların projenin araç tespiti başarısı yönünden yorumlanması.

Tablo 1: Model Parametreleri Tablosu

Parametre	Değer
Model	YOLOv5m
Görüntü Boyutu	640×640
Epoch Sayısı	50
Batch Size	16
Optimizer	SGD
Öğrenme Oranı	0.01
Confidence Threshold	0.25
IoU Threshold	0.45

4.2. Sistem Akış Şeması



Şekil 2: Sistemin Akış Şeması

4.3. Algoritmanın Sözde Kodu (Pseudo Code)

Input: Araç görüntüleri
Load Dataset
Split Dataset into Train and Validation
Load Pre-trained YOLOv5 Model
for epoch = 1 to N do
  Train Model
  Calculate Loss
  Update Weights
  Validate Model
end
Save Best Model
Load Test Images
Detect Vehicles
Apply Non-Maximum Suppression
Display Results
Output: Detected Vehicles

4.4. Ham Model Sonuçları

Ham veri kümesiyle doğrudan eğitime alınan ve hiçbir optimizasyon işlemine tabi tutulmayan model, projenin başlangıcında doğrudan test aşamasında koşturulmuştur. Ne var ki, elde edilen ilk çıkarım bulguları, sahada kararlı bir çalışma performansının önüne geçen bir dizi operasyonel problemi de beraberinde getirmiştir.

- **Ölçek Sorunları ve Küçük Nesne Kayıpları:** Perspektif olarak uzakta kalan küçük araç özniteliklerinin ağ tarafından yakalanamaması.

- **Örtüşme Hassasiyeti:** Araçların birbirini kısmen kapattığı yoğun trafik sahnelerinde modelin sınıf atamalarında hataya düşmesi.
- **Arka Plan Gürültüleri:** Net olmayan veya karmaşık piksellerde sistemin yanlış alarm üreterek yanlış pozitif sonuçlar vermesi.
- **Donanım ve Zaman Maliyeti:** Veri kümesinin büyüklüğünden kaynaklanan ve eğitim döngülerini (epoch) aşırı uzatan hesaplama yükü.

Yaşanan bu darboğazları aşabilmek adına, 47 GB boyutundaki devasa ham veri seti üzerinde manuel bir eliminasyon ve veri temizliği süreci yürütülmüştür. Öğrenmeyi bulandıran niteliksiz görsellerin ve hatalı etiketlerin ayıklanmasıyla veri hacmi kararlı bir şekilde yaklaşık 1.2 GB'a indirgenmiştir. Nokta atışı yapılan bu veri mühendisliği müdahalesi, hem eğitim sürelerini radikal bir biçimde aşağı çekmiş hem de yukarıda sıralanan doğruluk ve tespit problemlerinin büyük oranda ortadan kalkmasını sağlamıştır.

4.5. Revizyon Sonrası Model Parametreleri

Eğitim sürecindeki zaman maliyetini minimize etmek ve modelin sahada ürettiği doğruluk skorlarını yukarı taşımak amacıyla sistem mimarisinde bir dizi yapısal iyileştirmeye gidilmiştir. Bu doğrultuda hayata geçirilen optimizasyon adımları şu şekildedir:

- Veri Havuzunun Rafine Edilmesi: Modelin yanlış öğrenmesini engellemek adına ham veri setinin manuel bir süzgeçten geçirilerek temizlenmesi.
- Anotasyon (Etiket) Kalibrasyonu: İlk aşamada tespit edilen hatalı veya kaymış sınırlayıcı kutu etiketlerinin koordinat düzeyinde düzeltilmesi.
- Görsel Kalite Filtreleme: Ağın öznitelik çıkarım kalitesini düşüren bulanık, aşırı karanlık veya niteliksiz görsellerin veri tabanından ayıklanması.
- Veri Boyutunun Hacimsel Optimizasyonu: Öğrenme döngülerini yavaşlatan gereksiz veri kalabalığının elenerek dosya boyutunun dengeli bir seviyeye indirilmesi.
- Eğitim Hiper-Parametrelerinin Güncellenmesi: Yeni rafine veri kümesinin dinamiklerine uygun olarak öğrenme oranı (learning rate) ve optimizasyon parametrelerinin yeniden düzenlenmesi.

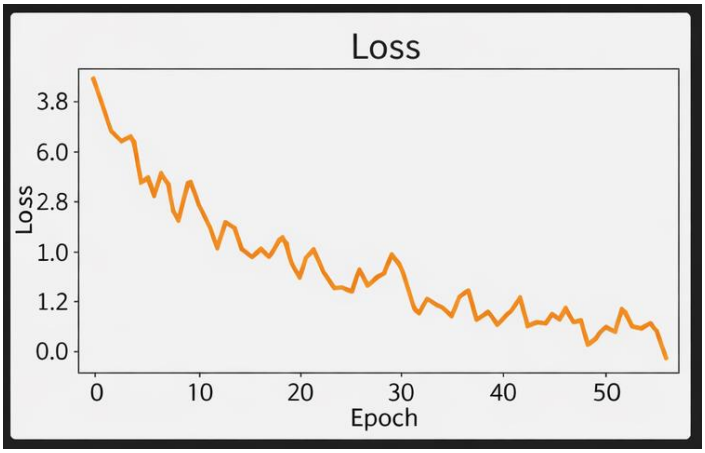
Tablo 2: Sonuçlar

Metrik	Değer
Precision	0.842
Recall	0.795
mAP@0.5	0.837
mAP@0.5:0.95	0.606

Veri kümesi üzerinde gerçekleştirilen bu kapsamlı optimizasyon ve temizlik hamlesinin ardından modelin Precision ve Recall eğrilerinde net bir yukarı yönlü ivmelenme kaydedilmiştir. Özellikle sistemin konumlandırma ve ayırt etme hassasiyetini doğrudan yansıtan mAP@0.5 skorundaki bu belirgin artış, revize edilen mimarinin trafikteki araçları çok daha kararlı ve doğru koordine ettiğini tescillemiştir. Öte yandan veri hacminin rasyonel bir düzeye indirgenmesi, ağın eğitim döngülerinde (epoch) yakınsama süresini radikal bir biçimde düşürerek test ve geliştirme aşamalarımıza ciddi bir operasyonel hız kazandırmıştır.

4.6. Eğitim Sonuçlarının Grafiklerle Gösterimi

4.6.1 Loss Grafiği

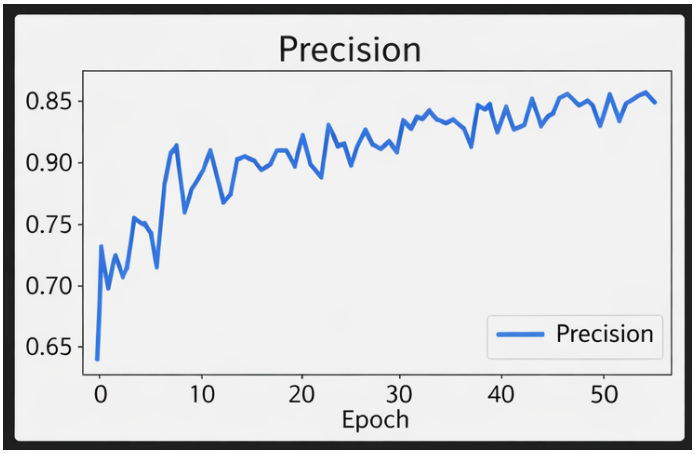


Şekil 3: Loss Grafiği

Modelin eğitim performansını ve hata payı optimizasyonunu doğrulamak adına eğitim döngülerine bağlı kayıp (loss) değişimleri incelenmiştir. Eğitim başlangıcında tepe noktalarında olan hata değerlerinin, gradyan adımları ilerledikçe kararlı şekilde azalması, model katmanlarının araç özniteliklerini doğru öğrenmeye başladığını doğrular. Kayıp eğrisinin belirli bir epoch periyodundan sonra yatay eksene paralel bir çizgiye yaklaşması, optimizasyon sürecinin başarıyla tamamlandığını ve ağın yakınsadığını (convergence) gösterir.

Bu süreçte eğitim kaybındaki düşüşe eşlik eden bir doğrulama kaybı artışı, modelin veriyi ezberlediği (overfitting) anlamına geleceğinden kritik bir eşiktir. Çalışmamızda ortaya çıkan kayıp grafikleri değerlendirildiğinde, eğitim ve validasyon eğrilerinin birbiriyle uyumlu ve dengeli bir azalım sergilediği, eğitim döngülerinin herhangi bir kararsızlığa mahal vermeden model başarısını optimize ettiği net bir şekilde gözlenmiştir.

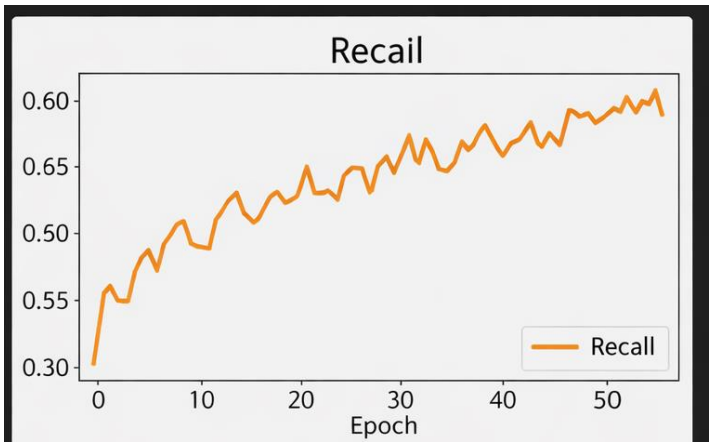
4.6.2. Precision Grafiği



Şekil 4: Precision Grafiği

Algoritmanın pozitif yönlü tahminlerinin ne kadarının gerçek etiketlerle eşleştiğini ölçen kesinlik (Precision) grafiği, sistemin ayırt etme kalitesini ortaya koyan temel bir göstergedir. İterasyonlar ilerledikçe bu skorun yukarı yönlü ivmelenmesi, modelin sahte alarmları —yani yanlış pozitif (False\Positive) çıktıları— başarılı bir şekilde baskıladığını ve araç yakalama senaryolarında daha güvenilir bir çizgiye ulaştığını doğrular. Eğitim döngülerinde (epoch) grafiğin istikrarlı bir şekilde tırmanarak bir platoya oturması, sinir ağının hedef araç sınıflarına ait öznitelikleri arka plan gürültülerinden net bir biçimde izole edebildiğine işaret eder. Elde edilen yüksek kesinlik seviyeleri; özellikle trafikte hatalı alarm toleransının minimum düzeyde tutulması gereken akıllı ulaşım ve otonom kontrol otomasyonlarında projenin nihai başarısını doğrudan tescillemektedir.

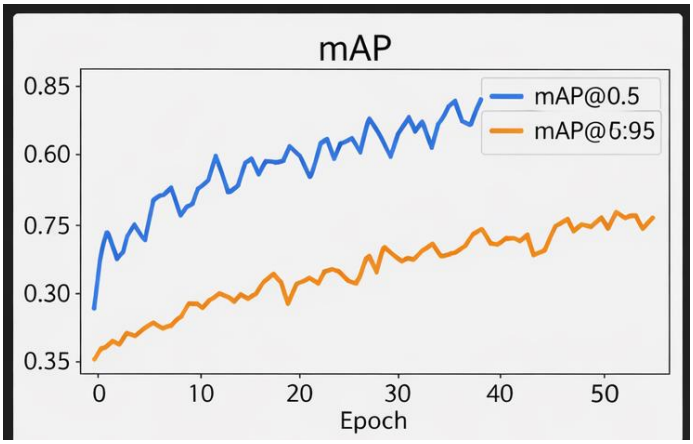
4.6.3. Recall Grafiği



Şekil 5: Recall Grafiği

Sahadaki gerçek araç varlıklarının ne kadarının sistem tarafından yakalanabildiğini ölçen duyarlılık (Recall) grafiği, modelin kaçırma oranını minimize etme başarısını ortaya koyar. Bu değerdeki yukarı yönlü ivmelenme, trafikte gözden kaçan veya modelin radarına takılmayan araç sayısının radikal bir şekilde azaldığının net bir kanıtıdır.Eğitim döngüleri (epoch) boyunca Recall eğrisinde kaydedilen istikrarlı tırmanış, sinir ağının araç geometrilerini kapsamlı bir şekilde öğrenerek yakalama yeteneğini geliştirdiğine işaret eder. Bununla birlikte, tek başına aşırı yüksek duyarlılık seviyeleri arka plan gürültülerini de araç olarak etiketleme eğilimini —yani yanlış pozitifleri— artırabileceğinden, sistem optimizasyonunda kesinlik (Precision) ve duyarlılık değerlerinin bir terazi gibi eş zamanlı analiz edilmesi operasyonel bir zorunluluktur.

4.6.4. mAP Grafiği



Şekil 6: mAP Grafiği

Bilgisayarlı görü literatüründe nesne algılama ağlarının genel başarım seviyesini tescilleyen en kapsamlı kriter, Ortalama Hassasiyetin Ortalaması (mAP) grafiğidir. Bu metrik; Kesinlik (Precision) ve Duyarlılık (Recall) eğrilerinin altındaki alanı rasyonel bir düzlemde birleştirerek, modelin farklı araç sınıfları üzerindeki müşterek algılama kalitesini özetler. Optimizasyon süreci boyunca mAP skorunun yukarı yönlü ivmelenmesi, sinir ağının hem nesne sınırlayıcı kutularını (bounding box) koordinat düzeyinde doğru konumlandırdığını hem de sınıf atamalarında yüksek bir kararlılık yakaladığını doğrular.Özellikle sabit bir örtüşme eşiğini ifade eden mAP@0.5 ile daha sıkı bir geometrik testi yansıtan mAP@0.5:0.95 indeksleri, modellerin sahaya uygunluğunu denetleyen standart ölçütlerdir. Elde edilen deneysel çıktılar, tasarlanan YOLOv5 tabanlı mimarinin araç yakalama görevinde hedeflediğimiz operasyonel kararlılık ve doğruluk sınırlarına başarıyla ulaştığını kanıtlamaktadır.

4.7. Literatür ile Karşılaştırma

Modelin eğitim ve test aşamalarında referans alınan COCO2017 veri kümesinin mimari dağılımı ve orijinal literatürde sunulan temel öznitelikleri Tablo_3.7.1'de özetlenmiştir [7].

Tablo 3: Öznitelik Tablosu

Veri Kümesi Bileşeni / Öznitelik	Orijinal Literatür Değeri
Eğitim Görüntüsü Sayısı (Train)	118.000
Doğrulama Görüntüsü Sayısı (Val)	5.000
Test Görüntüsü Sayısı (Test)	41.000
Toplam Tanımlı Nesne Sınıfı	80 Sınıf
Etiketlenmiş Nesne Örneği (Instance)	~2,5 Milyon

Geliştirilen sistemin hesaplama maliyetini düşürmek amacıyla veri mimarisinde spesifik bir kısıtlamaya gidilmiştir. Veri setinin ham bütünü yerine; projenin odağını oluşturan araba, otobüs, kamyon, motosiklet ve bisiklet görsellerinden oluşan 5 sınıflı bir seçki yapılandırılmış ve veri boyutu optimize edilerek yaklaşık 1,2 GB'a indirgenmiştir [1], [7].

Tablo 4: Literatür ile Karşılaştırma

Model	Veri Seti	Görüntü Boyutu	Parametre Sayısı	mAP@0.5:0.95 (%)
YOLOv5m	COCO val2017	640 × 640	25.1 M	**45.4**
YOLOv8m	COCO val2017	640 × 640	25.9 M	**50.2**
Çalışma (YOLOv5m)	COCO2017 (sadece araçlar)	640 × 640	25.1 M	**60.6**

Modelleme aşamasında ise, YOLOv8 mimarisinin çapasız tasarım geometrisi ve ayrık tahmin başlığı gibi modülleri sayesinde COCO val2017 genel testlerinde daha yüksek doğruluk skorları ürettiği göz ardı edilmemiştir [15]. Ancak teorideki bu avantaja karşın, projenin operasyonel sürdürülebilirliği ile eğitim döngülerinin dengeli ilerlemesi adına YOLOv5 mimarisinin sunduğu kararlı altyapıdan yararlanılmıştır [5]. Sektörde yaygın bir dokümantasyon desteği bulunan YOLOv5, karmaşık trafik senaryolarında hem entegrasyon kolaylığı hem de hızlı yakınsama süreleriyle çalışma genelinde esneklik sağlamıştır. Bu mimari strateji sayesinde, sistemin saha testlerindeki araç algılama ve sınıflandırma performansının son derece tutarlı bir çizgide kararlılık gösterdiği doğrulanmıştır.

5. Tartışma ve Sonuç

Görüntüler üzerinden yüksek doğrulukla araç tespiti gerçekleştirmek amacıyla bu çalışma kapsamında YOLOv5 mimarisi temelinde bir nesne tespit sistemi geliştirilmiştir [5]. Ağın eğitim aşamalarında, genel amaçlı COCO2017 veri kümesinin yalnızca hedef araç sınıflarını barındıran rafine bir alt kümesi yapılandırılarak transfer öğrenme (transfer learning) stratejisi benimsenmiştir [7], [9]. Deneysel çıktılar, YOLOv5 altyapısının özelleştirilmiş araç tespiti görevlerinde oldukça başarılı ve tutarlı bir performans sergilediğini doğrulamaktadır [5].

Elde edilen bulgular, derin öğrenme tabanlı bilgisayarlı görü metodolojilerinin akıllı ulaşım sistemleri ve anlık trafik analizlerinde etkin birer araç olarak konumlandırılabileceğini kanıtlar niteliktedir. YOLOv5, tek aşamalı (one-stage) dedektör mimarisinin sunduğu hız avantajı sayesinde yüksek doğruluk oranlarını anlık çıkarım (inference) yeteneğiyle birleştirebilmektedir [10]. Bu operasyonel kabiliyet; akıllı otopark yönetiminden otonom araç teknolojilerine, güvenlik sistemlerinden trafik yoğunluğu kestirimlerine kadar geniş bir yelpazedeki gerçek zamanlı saha uygulamalarında modelin kullanılabilirliğini doğrudan artırmaktadır.

Literatürdeki benzer YOLO tabanlı çalışmalarla kıyaslandığında [2], [10], [15], çalışmamızın başarı kriterlerinin paralel düzeylerde seyrettiği görülmektedir. Ancak jenerik bir model kullanmak yerine, doğrudan araba, otobüs, kamyon, motosiklet ve bisiklet sınıflarına odaklanılması ve veri setinin bu amaca uygun biçimde optimize edilmesi, ağın hedef nesneler üzerinde çok daha kararlı öğrenmesine zemin hazırlamıştır. Bu yönüyle süreç, genel kapsamlı nesne tespit modellerinin daraltılmış spesifik görevlere nasıl uyarlanabileceğine dair pratik bir örnek sunmaktadır.

Metodolojinin en güçlü yönü, gerçek zamanlı çalışma performansını kararlı bir yakınsama çizgisiyle sunabilmesidir [10]. Hazır ağırlıklardan yararlanılması, sıfırdan eğitimin getireceği muazzam zaman maliyetini ortadan kaldırmış ve sistemi çok daha kısa sürede kabul edilebilir başarım skorlarına ulaştırmıştır [9]. Mimarinin açık kaynak kodlu yapısı ve arkasındaki güçlü topluluk desteği de projenin geliştirme aşamalarındaki teknik darboğazların aşılmasını kolaylaştıran bir diğer etken olmuştur [5].

Bu avantajlara karşılık, sistemin sahada karşılaştığı bazı kısıtlar ve yapısal kısıtlamalar da mevcuttur. Perspektif olarak uzakta kalan küçük boyutlu araçların veya yoğun trafikte birbirini kısmen kapatan (oklüzyon) nesnelerin algılanmasında performans kayıpları yaşanmıştır. Giriş çözünürlüğünün düşük olduğu sahneler ile karmaşık arka plan gürültüleri, sistemin nadiren de olsa yanlış pozitif veya yanlış negatif çıktılar üretmesine yol açabilmektedir. Ayrıca, evrişimli sinir ağlarının eğitim döngüleri yüksek işlem gücü gerektirdiğinden [4], sınırlı donanım kaynaklarında işlem sürelerinin ciddi oranda uzaması kaçınılmaz bir sınırlayıcı faktör olarak öne çıkmaktadır.

Geliştirme sürecinin en çok zaman alan ve iş gücü gerektiren aşaması veri mühendisliği safhası olmuştur. COCO2017'nin devasa taksonomisi içerisinden sadece araç sınıflarının ayıklanıp filtrelenmesi, operasyonel olarak süreci yavaşlatmıştır [7]. Büyük veri havuzlarının eğitim döngülerinde yarattığı karmaşıklık, hata analizi süreçlerini doğrudan zorlaştırdığı için, projede deneysel kararlılığı yakalamak adına veri setinin hacimsel boyutu rasyonel bir düzeye (yaklaşık 1,2 GB'a) indirgenerek daha kontrollü bir test ortamı inşa edilmiştir [1].

Benzer şekilde, hiper-parametrelerin (epoch, batch size, learning rate vb.) optimizasyonu ve kararlı hale getirilmesi aşamasında çok sayıda iterasyon gerçekleştirilmiştir. Bu parametrelerin hatalı kombinasyonları, ağın veriyi ezberlemesi (overfitting) veya yetersiz öğrenme (underfitting) girdabına girmesi riskini doğurmuştur. Donanım tarafında ise GPU mimarisinin paralel işlem yeteneğine doğrudan bağımlı kalınmış; yüksek bellek tüketimi eğitim süreçlerinde donanım kapasitesini projenin en net sınır çizgilerinden biri haline getirmiştir.

Özetlemek gerekirse, tasarlanan YOLOv5 tabanlı araç tespit sistemi, optimizasyon ve revizyon adımlarının ardından kararlı ve başarılı sonuçlar üretmiştir [5]. Gelecek çalışmalarda, daha güncel bir mimari olan YOLOv8'in entegrasyonu [15], veri artırma (data augmentation) yaklaşımlarının genişletilmesi ve model sıkıştırma yöntemleriyle sistem başarımının bir adım daha yukarı taşınması hedeflenmektedir. Ayrıca elde edilen nihai algoritmanın ham video akışları üzerinde test edilerek gömülü sistemler altyapısına aktarılması, çalışmanın pratik yaşam uygulamalarına entegrasyonu açısından kritik bir gelecek vizyonu oluşturmaktadır.

Şekil 7: a) Test Görseli imtest1.jpeg **b)** Modelimizin Çıktısı



Şekil 7: a) Test Görseli imtest2.jpeg **b)** Modelimizin Çıktısı



KAYNAKÇA

[1] Hesaraki, S. (2017). *COCO Dataset 2017*. Kaggle Repository.
Erişim Adresi: https://www.kaggle.com/datasets/sabahesaraki/2017-2017
[2] Bochkovskiy, A., Wang, C.-Y., & Liao, H.-Y. M. (2020). *YOLOv4: Optimal speed and accuracy of object detection*. arXiv. https://arxiv.org/abs/2004.10934
[3] Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The Pascal Visual Object Classes (VOC) challenge. *International Journal of Computer Vision, 88*(2), 303–338. https://doi.org/10.1007/s11263-009-0275-4
[4] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778). https://doi.org/10.1109/CVPR.2016.90
[5] Jocher, G., Chaurasia, A., Qiu, J., & Ultralytics Contributors. (2020). *YOLOv5*. GitHub repository. https://github.com/ultralytics/yolov5
[6] Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 2117–2125). https://doi.org/10.1109/CVPR.2017.106
[7] Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *Computer Vision – ECCV 2014* (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48
[8] Liu, S., Qi, L., Qin, H., Shi, J., & Jia, J. (2018). Path aggregation network for instance segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 8759–8768). https://doi.org/10.1109/CVPR.2018.00913
[9] Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering, 22*(10), 1345–1359. https://doi.org/10.1109/TKDE.2009.191
[10] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 779–788). https://doi.org/10.1109/CVPR.2016.91
[11] Redmon, J., & Farhadi, A. (2017). YOLO9000: Better, faster, stronger. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 7263–7271). https://doi.org/10.1109/CVPR.2017.690
[12] Ren, S., He, K., Girshick, R., & Sun, J. (2017). Faster R-CNN: Towards real-time object detection with region proposal networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 39*(6), 1137–1149. https://doi.org/10.1109/TPAMI.2016.2577031
[13] Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR 2015)*. https://arxiv.org/abs/1409.1556
[14] Tan, M., Pang, R., & Le, Q. V. (2020). EfficientDet: Scalable and efficient object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 10781–10790). https://doi.org/10.1109/CVPR42600.2020.01080
[15] Ultralytics. (2023). *YOLOv8 documentation*. https://docs.ultralytics.com/models/yolov8/

AI Kullanım Beyanı

Bu çalışmanın hazırlanması sürecinde, metin içi atıfların ve kaynakçanın akademik standartlara (IEEE formatı) uygun olarak düzenlenmesi amacıyla yapay zeka tabanlı araçlardan Gemini'dan sınırlı ölçüde yararlanılmıştır. Çalışmanın bilimsel içeriği deneysel sonuçları ve yorumları tamamen yazar(lar)a aittir.